Guide 1 — Mise en place de l'environnement

Observatoire des disparités régionales en Tunisie — Ahmed Ben Arfa

Ce guide décrit, dans l'ordre, tout ce qui a été installé et configuré avant le premier job Talend : la base PostgreSQL, le fichier de configuration unique `.env`, puis le projet Talend (contextes, connexion, métadonnées). Pour chaque étape, il indique le *pourquoi*, pas seulement le *comment*, ainsi que les pièges rencontrés.

Documents liés : `architecture.md` (vue d'ensemble), `decisions.md` (journal des décisions), Guide 2 — Job J01.

---

1. Environnement de travail

Composant	Version	Remarque
Windows 11 Professionnel	10.0.26200	
Talend Open Studio for Data Integration	8.0.1 (build 20211109_1610)	Plus maintenu depuis janvier 2024
Java	JDK 17.0.12	Requis par Talend 8
PostgreSQL	18.1	Service `postgresql-x64-18`, démarrage automatique
Python	3.13	Environnement virtuel `.venv/` (téléchargements, extraction PDF, contrôles)
Power BI Desktop	installé	Phase de restitution

Les versions ont été relevées avant toute création d'objet : rien n'est supposé.

2. La base PostgreSQL

2.1 Principe : un utilisateur applicatif dédié (D-006)

Le compte `postgres` est un superutilisateur : il peut tout faire sur le serveur. Les jobs n'en ont pas besoin. On crée donc un utilisateur **`dwh_user`**, propriétaire de la seule base **`tunisia_dwh`** et de ses trois schémas, sans aucun droit sur le reste du serveur (principe du moindre privilège).

Schéma	Rôle
`staging`	Copie fidèle des sources, sans contrainte, rechargée entièrement à chaque exécution
`dwh`	Modèle en étoile : dimensions, faits, tables de référence, avec contraintes
`audit`	Journal des exécutions et des lignes rejetées

2.2 Les scripts SQL

Script	Exécuté par	Contenu
`sql/00_creation_base.sql`	`postgres`	Rôle `dwh_user`, base `tunisia_dwh` (UTF-8), schémas `staging`, `dwh`, `audit`. Le mot de passe est demandé de façon interactive (`\password`) : il n'apparaît ni dans le fichier ni dans l'historique. Relançable sans erreur.
`sql/01_audit.sql`	`dwh_user`	`audit.etl_run_log` (une ligne par exécution de job) et `audit.etl_rejets` (une ligne par ligne rejetée, avec son motif)
`sql/02_staging_hdx.sql`	`dwh_user`	`staging.stg_hdx_admin2` : copie de la feuille HDX des gouvernorats, plus les colonnes de traçabilité
`sql/03_dwh_dim_gouvernorat.sql`	`dwh_user`	`dwh.dim_gouvernorat` et ses contraintes de contrôle

Commandes (invite de commandes Windows, à la racine du dépôt) :

```
psql -U postgres -h localhost -f sql/00_creation_base.sql
psql -f sql/01_audit.sql
psql -f sql/02_staging_hdx.sql
psql -f sql/03_dwh_dim_gouvernorat.sql
```

Les trois dernières commandes n'indiquent ni utilisateur ni base : `psql` lit les variables `PG*` de l'environnement, chargées depuis `.env` (section 3).

2.3 Les contraintes de `dim_gouvernorat`, premier filet de qualité

La dimension refuse d'elle-même une ligne incohérente, même si un job laissait passer une erreur :

Contrainte	Règle
`pk_dim_gouvernorat`	Le P-code est unique
`ck_pcode_format`	P-code de la forme `TN` + région (1 à 6) + rang (1 à 9)
`ck_pcode_dans_region`	Les trois premiers caractères du P-code sont ceux de la région HDX
`ck_nom_ar_sans_tatweel`	Le nom arabe ne contient plus de caractère d'allongement (U+0640, D-009)
`ck_district`	District entre 1 et 5 (décret 2023-589, D-004)
`ck_centroide_tunisie`, `ck_chef_lieu_tunisie`	Coordonnées dans les limites de la Tunisie (30–38° N, 7–12° E)
`ck_chef_lieu_complet`	Latitude et longitude du chef-lieu toutes deux renseignées ou toutes deux vides
`ck_sha256`	Empreinte du fichier source au format SHA-256

Ces contraintes ont été testées avant le premier job : les 24 gouvernorats réels sont acceptés, et 6 lignes volontairement fausses sont toutes refusées. Le test a été annulé (`ROLLBACK`) : la table était vide au démarrage de J01.

3. Une configuration unique : le fichier `.env`

Un seul fichier, à la racine du dépôt, sert à **psql**, aux **scripts Python** et à **Talend**. Il est ignoré par git ; le modèle versionné est `.env.example`.

```
PGHOST=localhost
PGPORT=5432
PGDATABASE=tunisia_dwh
PGUSER=dwh_user
PGPASSWORD=
PGSCHEMA=
PGPARAMS=
RACINE_PROJET=D:/Projet/tunisia-regional-data-warehouse
```

- Les noms `PG*` sont les variables standard de PostgreSQL : `psql` les lit sans paramètre.
- Les mêmes noms sont utilisés pour les variables de contexte Talend, qui les lit au lancement de chaque job.
- Le fichier ne contient que des lignes `CLE=valeur`, **sans commentaire** : Talend lirait un commentaire comme une variable.
- `PGSCHEMA` et `PGPARAMS` sont vides mais présents : la connexion Talend en mode contexte les exige (section 4.3).

4. Le projet Talend

4.1 Lancer Talend en administrateur

L'espace de travail se trouve sous `C:\Program Files (x86)\…`. Windows y interdit l'écriture à un utilisateur standard : Talend doit être lancé **en tant qu'administrateur**, sinon les modifications ne sont pas enregistrées.

Si la disposition des fenêtres est perdue : relancer Talend en administrateur avec l'option `-clearPersistedState`.

4.2 Les groupes de contexte

Projet `TUNISIA_DWH`, environnement de contexte unique `DEV` (l'environnement `Default` créé par Talend a été supprimé, pour qu'il n'y ait qu'une source de valeurs).

Groupe	Variables	Usage
`ctx_dwh`	`PGHOST`, `PGPORT`, `PGDATABASE`, `PGUSER`, `PGPASSWORD`, `PGSCHEMA`, `PGPARAMS`	Connexion à la base
`ctx_chemins`	`RACINE_PROJET`	Base de tous les chemins de fichiers

Pourquoi deux groupes ? La connexion du référentiel ne peut être reliée (« Export as context ») qu'à un groupe dont **chaque** variable correspond à l'un de ses champs. Un groupe unique contenant aussi `RACINE_PROJET` était refusé.

Le mot de passe : dans Talend, `PGPASSWORD` est de type mot de passe et sa valeur reste **vide**. Il n'est lu que dans `.env`, au lancement. Il n'apparaît donc dans aucun fichier du projet Talend ni dans les exports de jobs.

4.3 La connexion `cnx_tunisia_dwh`

Métadonnées → Connexions de bases de données, PostgreSQL, version « v9 and later ». Chaque champ pointe vers une variable de contexte :

Champ	Valeur
Serveur	`context.PGHOST`
Port	`context.PGPORT`
Base de données	`context.PGDATABASE`
Utilisateur	`context.PGUSER`
Mot de passe	`context.PGPASSWORD`
Schéma	`context.PGSCHEMA` (vide)
Paramètres additionnels	`context.PGPARAMS` (vide)

Pièges rencontrés :

- Talend avertit que le champ *Schéma* doit être rempli en mode contexte : on valide avec OK et on le laisse vide. Le schéma est choisi dans chaque composant (voir le Guide 2, « schéma alternatif »).
- Dans le tableau de correspondance des variables, le bouton *Finish* reste grisé tant que la dernière cellule modifiée n'a pas été validée avec Entrée.

4.4 Chargement implicite du contexte

Fichier → Éditer les propriétés du projet → Paramètres du job → Implicit tContextLoad :

Paramètre	Valeur
Activé	oui
Source	From File
Fichier	`"D:/Projet/tunisia-regional-data-warehouse/.env"`
Séparateur de champs	`"="`
Print operations	oui

Avec *Print operations*, chaque exécution affiche dans la console les variables chargées, mot de passe masqué :

```
Implicit_Context_Context set key "PGHOST" with value "localhost"
Implicit_Context_Context set key "PGPASSWORD" with value "*********"
Implicit_Context_Context set key "RACINE_PROJET" with value "D:/Projet/tunisia-regional-data-warehouse"
```

4.5 La métadonnée Excel `hdx_admin2`

Métadonnées → Fichier Excel, fichier `data/raw/hdx/tun_admin_boundaries.xlsx`, feuille **`tun_admin2`** (les 24 gouvernorats), en-tête sur la ligne 1.

Piège rencontré : l'assistant a repris la structure de la première feuille du classeur (`tun_admin0`, 18 colonnes) au lieu de celle de `tun_admin2` (26 colonnes), et refusait « Dernière colonne : 26 ». Solution : vider ce champ, puis ajouter à la main les 8 colonnes manquantes dans l'éditeur de schéma.

Schéma final, 26 colonnes dans l'ordre du fichier :

Colonnes	Type
`adm2_name`, `adm2_name1` à `adm2_name3`, `adm2_pcode`, `adm1_name`, `adm1_name1` à `adm1_name3`, `adm1_pcode`, `adm0_name`, `adm0_name1` à `adm0_name3`, `adm0_pcode`	String
`valid_on`	Date, modèle `"dd-MM-yyyy"`
`valid_to`, `version`, `lang`, `lang1` à `lang3`, `adm2_ref_name`	String
`area_sqkm`, `center_lat`, `center_lon`	Double

Revenir en arrière dans l'assistant réinitialise les types : ils ont été corrigés ensuite par *Éditer le schéma*.

5. Récapitulatif des pièges

Symptôme	Cause	Solution
Modifications Talend non enregistrées, disposition cassée	Espace de travail sous Program Files	Lancer en administrateur ; `-clearPersistedState`
« Export as context » refusé	Groupe contenant une variable sans champ correspondant	Un groupe par usage (`ctx_dwh`, `ctx_chemins`)
Finish grisé	Dernière cellule non validée	Entrée avant *Finish*
Assistant Excel bloqué à 18 colonnes	Structure lue sur la première feuille	Ajouter les colonnes à la main
Types du schéma Excel perdus	Retour arrière dans l'assistant	Les corriger dans *Éditer le schéma*
Après l'export d'un job, les autres jobs ont disparu de `talend/`	*Exporter des éléments* vers un répertoire remplace son contenu par les seuls éléments sélectionnés	Exporter **tous les jobs ensemble**, avec leurs dépendances (contextes, connexion, métadonnées, routines)

Précaution prise d'emblée (pas un incident) : aucun commentaire dans `.env`, car le chargement implicite lirait chaque ligne comme une variable.

Version PDF de `docs/guides/01_mise_en_place.md`, générée le 11/11/2026.