Architecture

Chaîne de traitement

```
Sources brutes (PDF, XLSX, API)
        │
        ├─ scripts Python : téléchargement, extraction des tableaux PDF en CSV
        ▼
data/raw/ (intouchable)  →  data/extracted/ (CSV issus des PDF)
        │
        ▼
Talend Open Studio : nettoyage, référentiel géographique, contrôles qualité, orchestration
        │
        ▼
PostgreSQL : schémas staging → dwh (schéma en étoile) + audit
        │
        ▼
Power BI : carte, indice composite, côte / intérieur, tourisme, comparaison avec l'IDR
```

Environnement

Relevé le 9 novembre 2026.

Composant	Version	Emplacement
Système	Windows 11 Professionnel (10.0.26200)	
Talend Open Studio for Data Integration	8.0.1 (build 20211109_1610)	`C:\talend`
Java	JDK 17.0.12	`C:\Program Files\Java\jdk-17`
PostgreSQL	18.1 (service `postgresql-x64-18`, démarrage automatique)	`C:\Program Files\PostgreSQL\18`
Pilote JDBC PostgreSQL	pgJDBC	`C:\Program Files (x86)\PostgreSQL\pgJDBC`
Python	3.13	environnement virtuel `.venv/` du dépôt
Power BI Desktop	installé	`C:\Program Files\Microsoft Power BI Desktop`
Git	installé	

Configuration

Un seul fichier de configuration locale, `.env`, à la racine du dépôt. Il est ignoré par git ; le modèle versionné est `.env.example`. Il est lu par :

- **psql** et les scripts Python : les variables `PG*` sont les variables standard de PostgreSQL (libpq) ;
- **Talend** : chargement implicite du contexte (paramètres du projet, *Implicit tContextLoad*, « From File », séparateur `=`), fichier lu au lancement de chaque job. Les variables de contexte portent les mêmes noms que les clés du fichier.

Le fichier ne contient que des lignes `CLE=valeur`, sans commentaire.

Clé	Groupe de contexte Talend	Rôle
`PGHOST`, `PGPORT`, `PGDATABASE`	`ctx_dwh`	Serveur et base PostgreSQL
`PGUSER`, `PGPASSWORD`	`ctx_dwh`	Utilisateur applicatif `dwh_user` (décision D-006)
`PGSCHEMA`, `PGPARAMS`	`ctx_dwh`	Vides. Exigés par la connexion Talend en mode contexte ; le schéma est choisi dans chaque composant (`staging`, `dwh`, `audit`)
`RACINE_PROJET`	`ctx_chemins`	Chemin absolu du dépôt, base de tous les chemins de fichiers des jobs

Projet Talend

- Projet `TUNISIA_DWH`, environnement de contexte `DEV`.
- Deux groupes de contexte : `ctx_dwh` (connexion, 7 variables) et `ctx_chemins` (chemins). La connexion du référentiel ne peut être reliée qu'à un groupe dont chaque variable correspond à l'un de ses champs, d'où la séparation.
- Connexion du référentiel `cnx_tunisia_dwh` (PostgreSQL, « v9 and later ») : tous ses champs pointent vers `ctx_dwh` (`context.PGHOST`, etc.).
- Dans le projet Talend, la valeur de `PGPASSWORD` est **vide** : le mot de passe n'est lu que dans `.env`, au lancement. Il n'apparaît donc pas dans les exports de jobs.
- Une seule connexion par job (`tDBConnection`, libellé `cnx_dwh`), partagée par tous les composants de base et validée explicitement par un `tDBCommit` (pas d'auto-commit).
- Choix du schéma PostgreSQL : en connexion partagée, un composant de sortie reprend le schéma de la connexion, vide ici. Chaque sortie précise donc le sien dans **Paramètres avancés → Utiliser un schéma alternatif** (`"staging"`, `"dwh"` ou `"audit"`), et le champ **Table** ne contient que le nom de la table. Écrire `"staging.ma_table"` dans **Table** ne fonctionne pas : Talend met le nom entier entre guillemets (`INSERT INTO "staging.ma_table"`), et PostgreSQL y voit une table unique dont le nom contient un point. Les composants de lecture (`tDBInput`) utilisent une requête SQL et y qualifient la table (`staging.stg_hdx_admin2`).

Remarque : Talend Open Studio n'est plus maintenu depuis janvier 2024. La version 8.0.1 reste utilisable pour ce projet ; des pistes de migration sont présentées dans le README.
